

Architecture Data – POC Avantages Sportifs

CE PROJET A POUR OBJECTIF DE DÉMONTRER LA MISE EN PLACE COMPLÈTE D'UN PIPELINE DATA PERMETTANT DE TRANSFORMER DES DONNÉES RH ET SPORTIVES EN INDICATEURS DÉCISIONNELS EXPLOITABLES POUR L'ENTREPRISE.



CONTEXTE

La direction souhaite transformer la pratique sportive des salariés en un levier de motivation et de performance, afin d'encourager une activité physique plus régulière, tout en renforçant la cohésion interne grâce à un système d'avantages automatisé basé sur la donnée.

Enjeux métier


- Valoriser le sport comme facteur de bien-être et de performance au sein de l'entreprise
- Encourager une pratique sportive régulière via un système de récompenses automatisé
- Fiabiliser les déclarations de transport domicile-travail grâce à la donnée
- Réduire les erreurs et incohérences déclaratives
- Transformer les données sportives en outil de pilotage RH et financier

Objectifs du POC

- Tester la faisabilité d'un pipeline data complet de bout en bout (simulation → ingestion → transformation → restitution)
- Identifier les données nécessaires au calcul des avantages RH (prime + jours bien-être)
- Mesurer l'impact financier des dispositifs proposés
- Automatiser un traitement fiable, reproductible et scalable sans intervention manuelle

Architecture Globale du Pipeline

Une architecture Data Lakehouse complète a été mise en place afin de simuler un environnement de production réel, orchestrant la génération, l'ingestion temps réel, le traitement analytique multi-couches et la restitution.



PRÉPARATION DU RÉFÉRENTIEL RH (NETTOYAGE + FUSION)

Afin de construire une base de référence fiable pour l'ensemble du pipeline, les données RH et sportives ont été nettoyées, standardisées puis fusionnées pour créer un référentiel unique par salarié, servant de socle pour l'ensemble des traitements en aval.

1 Nettoyage des données RH et sportives

- Standardisation des colonnes (noms, formats, types)
- Nettoyage des valeurs manquantes et incohérences
- Harmonisation des formats de transport et des identifiants

🎯 Objectif : garantir des données exploitables et cohérentes

🧠 Pourquoi cette étape est essentielle ?

- Éviter les erreurs dans les calculs de primes
- Assurer la cohérence entre RH et activités sportives
- Créer la base de vérité utilisée dans tout le pipeline
- Permettre le calcul fiable des KPI en aval

2 Fusion des deux sources de données

- Jointure sur `employee_id`
- Création d'un référentiel unique salarié + activité
- Enrichissement des données RH avec les pratiques sportives

📊 Résultat : une vision 360° de chaque salarié

📦 Résultat produit

Un dataset consolidé utilisé pour :

🏠 Calcul des distances domicile-travail

⚠️ Détection des erreurs de déclaration

💰 Calcul des avantages RH (Gold)

CALCUL DES DISTANCES DOMICILE-ENTREPRISE

Après la collecte des données RH et sportives, cette étape enrichit chaque salarié avec une information clé : la distance entre son domicile et l'entreprise. Ce calcul permet de vérifier la cohérence des déclarations de transport et de fiabiliser les données avant leur exploitation dans les couches analytiques.

RÔLE DE CETTE ÉTAPE

Cette étape permet de compléter le jeu de données :

- En calculant automatiquement la distance domicile-entreprise à partir des adresses des salariés.
- Les données obtenues servent ensuite à appliquer les règles métier liées à la mobilité douce.

FONCTIONNEMENT

À partir des données fusionnées, plusieurs traitements sont réalisés :

- Récupération de l'adresse du domicile du salarié.
- Utilisation de l'adresse fixe de l'entreprise.
- Calcul de la distance avec Google Maps Distance Matrix API.
- Adaptation du mode de calcul selon le transport déclaré (marche, vélo ou voiture).
- Réutilisation des distances déjà calculées grâce à un système de cache afin d'éviter des appels API inutiles.

CONTRÔLE DE COHÉRENCE

Les distances calculées sont comparées au mode de transport déclaré afin de détecter d'éventuelles incohérences :

- Marche / Running : distance maximale autorisée de 15 km.
- Vélo / Trottinette : distance maximale autorisée de 25 km.

Si ces seuils sont dépassés, une anomalie est détectée et enregistrée dans la colonne `erreur_declaration_transport`.

RÉSULTAT

Le jeu de données est enrichi avec deux nouvelles informations :

- Distance domicile-entreprise (`distance_domicile_entreprise_km`).
- Indicateur d'anomalie (`erreur_declaration_transport`).
- Ces données enrichies sont ensuite utilisées par la couche Silver pour les traitements de qualité, puis par la couche Gold pour le calcul des indicateurs métier.

INGESTION DES DONNÉES (FASTAPI + POSTGRESQL)

Les données sportives sont simulées puis injectées via une API REST développée avec FastAPI, afin de reproduire un flux d'ingestion réaliste de type application mobile (Strava-like), permettant de tester un pipeline de données en conditions proches de la production.

FastAPI (API d'ingestion)

- Permet de recevoir les activités sportives simulées
- Expose une API REST simple et rapide
- Simule une application mobile ou IoT (type Strava)
- Point d'entrée unique pour centraliser l'ingestion des données

Pourquoi FastAPI ?

- Très hautes performances grâce au modèle asynchrone
- Développement rapide et léger (idéal POC)
- Format JSON natif parfaitement adapté aux flux événementiels
- Très utilisé dans les architectures modernes data / API

 Permet de simuler un service de type production sans surcomplexité

Sécurité & contrôle (FastAPI)

- API exécutée uniquement en environnement local (localhost)
- Aucun accès public → réduction des risques d'injection externe
- Flux de données contrôlé via scripts internes uniquement
- Environnement POC sécurisé et reproductible

 Cela garantit un contrôle total de l'ingestion dans un contexte non-production

PostgreSQL (base transactionnelle)

- Stocke les événements sportifs bruts
- Garantit la cohérence des données (ACID)
- Sert de base source avant le streaming (Debezium)
- Historise les activités avant traitement analytique

Pourquoi PostgreSQL ?

- Système robuste et éprouvé en production
- Gestion ACID → garantit l'intégrité des données RH sensibles
- Très bon support des données structurées (SQL)
- Facilement connectable au streaming via CDC (Debezium)
- Standard industriel dans les architectures data

STREAMING ÉVÉNEMENTIEL

Afin de poursuivre le pipeline après l'injection des activités sportives dans la base transactionnelle, une architecture de streaming événementiel a été mise en place pour capter en temps réel les données générées et les diffuser de manière découplée vers les différentes étapes de traitement.

Pourquoi le streaming ?

- Éviter un traitement batch manuel ou retardé
- Obtenir une donnée exploitable immédiatement après son écriture
- Découpler complètement la base de données et le pipeline analytique
- Garantir une scalabilité en cas d'augmentation du volume de données

🎯 Objectif principal

Passer d'un système "statique" à un système "temps réel"

Capture - Debezium (CDC)

CAPTURE DES ÉVÉNEMENTS

- Détection automatique des INSERT, UPDATE et DELETE
- Lecture des logs internes de PostgreSQL (WAL)
- Transformation de chaque changement en événement structuré

POURQUOI CETTE APPROCHE ?

- Évite de requêter la base en continu (polling inefficace)
- Garantit une capture exhaustive et fiable des données
- Minimise la charge sur la base transactionnelle

⚙️ Technologie : Debezium

- Standard industriel de la capture CDC
- Fiable, open-source & intégré nativement à PG

Diffusion - Redpanda

DIFFUSION DES ÉVÉNEMENTS

- Centralisation des événements dans un flux unique
- Distribution vers plusieurs consommateurs (Slack, Spark, etc.)
- Gestion du débit de données de manière scalable

POURQUOI UN BROKER ?

- Découpler la production et la consommation
- Absorber facilement les pics de charge
- Garantir la haute résilience globale du système

⚡ Technologie : Redpanda

- Compatible Kafka & ultra simple à exploiter
- Très faible latence, idéal data engineering moderne

NOTIFICATIONS TEMPS RÉEL DANS SLACK

Afin de répondre à la demande de Juliette visant à valoriser les activités sportives des salariés et à renforcer la cohésion interne, chaque activité enregistrée dans le système est automatiquement transformée en message de félicitation publié dans le canal Slack de l'entreprise, quelques secondes seulement après sa création.

🔧 FONCTIONNEMENT

Lorsqu'une nouvelle activité sportive est enregistrée :

- 1 L'événement est capturé par Debezium depuis PostgreSQL.
- 2 Il est publié dans un topic Redpanda.
- 3 Le script `06_consommer_slack.py` consomme le message.
- 4 Un message personnalisé est généré automatiquement.
- 5 Le message est envoyé dans le canal Slack de l'entreprise.

📌 RÉPONSE DIRECTE AU BESOIN MÉTIER

Cette fonctionnalité répond précisément à la demande formulée par Juliette dans le cahier des charges :

« Chaque activité physique doit créer automatiquement une publication dans le channel Slack associé afin de favoriser l'émulation entre les salariés. »

👥 RENFORCEMENT DE LA COHÉSION INTERNE

- Les salariés voient les activités des autres collaborateurs.
- Création d'une dynamique collective autour du sport.
- Favorise les échanges et le partage d'expériences.

📄 EXEMPLE DE MESSAGE GÉNÉRÉ

tous-consommersport

👤 Inviter des collègues 🔊

LM

Laurence Morvan 18:41

🏈 Bravo Bravo Laurence Morvan ! Une session de rugby de 14.5 km en 23 min !
Quelle énergie ! 🔥 ! Séance intense 🙌🔥

- Mettre en avant les efforts réalisés.
- Encourager la pratique sportive régulière.
- Créer un sentiment de reconnaissance.

🔍 POURQUOI UNE ARCHITECTURE ÉVÉNEMENTIELLE AVEC REDPANDA ?

- Les activités sont diffusées dès leur création.
- Aucun traitement manuel n'est nécessaire.
- Les consommateurs sont découplés de la base PostgreSQL.
- Plusieurs usages peuvent être ajoutés sans modifier l'application source :

Notifications Slack

Analyses temps réel

Alertes

Nouveaux dashboards

♀️ AVANTAGES

- Réactivité quasi temps réel
- Architecture évolutive
- Faible couplage entre les composants
- Facilité d'ajout de nouveaux consommateurs

INGESTION STREAMING & COUCHE BRONZE (DATA LAKE)

Une fois les événements sportifs diffusés dans le système de streaming, ils sont consommés en temps réel par Spark Structured Streaming puis persistés dans la couche Bronze du Data Lake. Cette étape permet de conserver l'intégralité des données brutes, sans transformation métier, afin de garantir la traçabilité, la rejouabilité et la fiabilité du pipeline de données.

RÔLE DE LA COUCHE BRONZE (MODÈLE MÉDAILLON)

La couche Bronze représente la première étape du Data Lakehouse (modèle Médaille).

Son rôle principal est de :

- Conserver les données brutes telles qu'elles arrivent du flux
- Garantir une trace complète des événements
- Servir de base fiable pour les transformations Silver et Gold

C'est une couche technique, pas encore métier.

DONNÉES STOCKÉES EN BRONZE

Les données ingérées contiennent notamment :

- Identifiant de l'activité
- Identifiant salarié
- Type de sport
- Distance parcourue
- Date de début / fin
- Commentaire utilisateur
- Durée calculée de l'activité

Ces données sont stockées sans logique métier appliquée.

POURQUOI SPARK STRUCTURED STREAMING ?

Spark Structured Streaming est utilisé car les données arrivent en continu via Redpanda.

Avantages principaux :

- Traitement temps réel des événements
- Consommation automatique des nouveaux messages
- Intégration native avec Delta Lake
- Capacité à gérer de forts volumes de données

Cela permet de transformer un flux événementiel en données exploitables immédiatement.

POURQUOI DELTA LAKE ?

Les données sont stockées dans Delta Lake, qui apporte des garanties industrielles :

Avantages clés :

- Transactions ACID (fiabilité des écritures)
- Historisation des données (time travel)
- Meilleure performance sur gros volumes
- Compatibilité native avec Spark
- Gestion robuste des mises à jour et suppressions

POURQUOI UNE COUCHE BRONZE ?

La couche Bronze est essentielle dans une architecture moderne car elle assure :

- **Conservation des données brutes**
 - Aucune transformation métier
 - Données identiques à la source
- **Rejouabilité du pipeline**
 - Possibilité de relancer Silver / Gold en cas d'erreur
- **Traçabilité complète**
 - Chaque événement peut être retrouvé
- **Séparation des responsabilités**
 - Bronze → ingestion
 - Silver → nettoyage
 - Gold → KPI métier

COUCHE SILVER : NETTOYAGE & ENRICHISSEMENT

Après la collecte des données brutes dans la couche Bronze, une étape de transformation est réalisée afin de nettoyer, standardiser et enrichir les événements sportifs avec les informations du référentiel RH. Cette étape permet de produire un jeu de données fiable, cohérent et directement exploitable pour le calcul des indicateurs métier.

RÔLE DE LA COUCHE SILVER

La couche Silver correspond au niveau intermédiaire de l'architecture Médaille (Medallion Architecture).

Elle transforme les données brutes en données fiables, homogènes et prêtes à être exploitées par les traitements analytiques.

POURQUOI CETTE ÉTAPE EST ESSENTIELLE ?

- **Fiabiliser les données**
 - garantir des données de qualité avant les calculs métier.
- **Construire une base homogène**
 - toutes les données suivent les mêmes formats et les mêmes règles.
- **Préparer le calcul des KPI**
 - les indicateurs de la couche Gold reposent sur une base fiable.
- **Garantir la reproductibilité**
 - les traitements peuvent être rejoués sans perte de cohérence.

TRANSFORMATIONS RÉALISÉES

Dans cette étape, les données sont :

NETTOYÉES

suppression des doublons d'activités ; gestion des valeurs manquantes.

STANDARDISÉES

harmonisation des différents formats de dates ; conversion des types de données (timestamp, entier, décimal).

NORMALISÉES

uniformisation des distances ; remplacement des valeurs nulles par des valeurs par défaut sécurisées.

ENRICHIES

jointure avec le référentiel RH ; ajout des informations salarié :

- mode de transport déclaré ;
- distance domicile-entreprise ;
- statut de contrôle du transport (OK / FRAUDE / INCONNU).

CONTRÔLÉES

détection des anomalies (ex. distances négatives) ; sécurisation des données avant leur exploitation.

COUCHE GOLD : CALCUL DES KPI MÉTIER

Après avoir obtenu des données propres et enrichies dans la couche Silver, la dernière étape du pipeline consiste à calculer les indicateurs métier attendus par Juliette. La couche Gold transforme les données techniques en indicateurs décisionnels directement exploitables par les équipes RH pour le pilotage des avantages sportifs.

RÔLE DE LA COUCHE GOLD

La couche Gold représente le niveau décisionnel de l'architecture Médaillon.

Elle consolide les données de la couche Silver afin de produire les indicateurs utilisés par les ressources humaines et le tableau de bord décisionnel.

POURQUOI CETTE COUCHE EST IMPORTANTE ?

- **Centralise les KPI**
Centralise les KPI métier dans une table unique.
- **Prépare le reporting**
Prépare directement les données pour le reporting.
- **Agilité des règles**
Permet de modifier facilement les règles métier (montant de la prime, critères d'éligibilité, etc.).
- **Découplage strict**
Sépare clairement les traitements techniques de la logique métier.

CALCULS RÉALISÉS

À partir des données Silver, plusieurs traitements sont effectués :

- **Période de référence**
Filtrage des activités réalisées au cours des 12 derniers mois.
- **Aggregation**
Regroupement des activités par salarié.
- **Filtrage de conformité**
Comptage du nombre d'activités sportives valides.
- **Volume global**
Calcul du nombre total d'activités sportives.
- **Avantage financier**
Calcul automatique de la prime sportive.
- **Avantage social**
Détermination de l'éligibilité aux journées bien-être.

RÈGLES MÉTIER APPLIQUÉES

PRIME SPORTIVE

Le salarié devient éligible à la prime lorsqu'il utilise un mode de transport doux (vélo, trottinette, marche ou running).

La prime correspond à 5 % du salaire brut annuel.

JOURNÉES BIEN-ÊTRE

Le salarié bénéficie des 5 journées bien-être lorsqu'il réalise : au moins 15 activités sportives au cours des 12 derniers mois.

STOCKAGE FINAL

Les indicateurs calculés sont enregistrés dans la couche Gold du Data Lake au format Delta Lake.

Ils sont ensuite exportés au format CSV afin d'alimenter le tableau de bord réalisé sous Tableau Public.

RÉSULTATS : TABLEAU PUBLIC

Une fois les indicateurs calculés dans la couche Gold, les résultats sont visualisés dans Tableau Public afin de transformer les KPI RH en tableaux de bord interactifs et lisibles pour la prise de décision.

OBJECTIF DE TABLEAU PUBLIC

- Visualiser les KPI RH sous forme de graphiques interactifs
- Faciliter l'analyse des performances sportives des salariés
- Identifier les tendances et comportements
- Aider la prise de décision RH

Apport pour l'entreprise :

- Passage de données techniques à une analyse métier
- Décisions RH mais plus rapides et visuelles
- Meilleure compréhension des comportements salariés
- Pilotage des avantages sociaux basé sur la data


TYPES DE VISUALISATIONS RÉALISÉES

- Répartition des activités sportives par salarié
- Distribution des primes sportives
- Activités sportives sur les 12 derniers mois
- Éligibilité aux jours bien-être
- Comparaison salariés actifs vs inactifs

Lecture des résultats :

- Les salariés les plus actifs sportivement
- L'impact financier des primes sportives
- Les comportements de mobilité et d'activité
- La distribution globale des KPI RH

ILLUSTRATION DES RÉSULTATS



Nom	Prenom	Moyen Transport	Eligible Jours Bien Etre	Nombre total activites
Amaud	Jeremy	VÉHICULE THERMIQUE/ÉL...	Faux	8
Baudry	Gilles	VÉLO/TROTTINETTE/AUT...	Faux	6
Bazin	Margaret	VÉLO/TROTTINETTE/AUT...	Faux	4
Bernard	Denise	VÉLO/TROTTINETTE/AUT...	Vrai	18
Besson	Hugues	MARCHE/RUNNING	Vrai	28
Blin	Léa	VÉHICULE THERMIQUE/ÉL...	Vrai	16
Boutin	Philippine	VÉLO/TROTTINETTE/AUT...	Vrai	15
Boyer	Julie	VÉLO/TROTTINETTE/AUT...	Faux	8
Breton	Jeannine	MARCHE/RUNNING	Vrai	16
Carlier	Constance	VÉHICULE THERMIQUE/ÉL...	Vrai	15



Nom	Prenom	Moyen Transport	Distance Domicile Entreprise Km	Montant Prime Sportive
Amaud	Jeremy	VÉHICULE THERMIQUE/ÉL...	42	0
Baudry	Gilles	VÉLO/TROTTINETTE/AUT...	12	1783
Bazin	Margaret	VÉLO/TROTTINETTE/AUT...	6	1573
Bernard	Denise	VÉLO/TROTTINETTE/AUT...	5	2127
Besson	Hugues	MARCHE/RUNNING	5	3618
Blin	Léa	VÉHICULE THERMIQUE/ÉL...	2	0
Boutin	Philippine	VÉLO/TROTTINETTE/AUT...	18	3656
Boyer	Julie	VÉLO/TROTTINETTE/AUT...	9	1809
Breton	Jeannine	MARCHE/RUNNING	5	2422
Carlier	Constance	VÉHICULE THERMIQUE/ÉL...	17	0

CONCLUSION DU PROJET

Ce projet a permis de concevoir une chaîne de traitement complète, depuis l'intégration des données jusqu'à la production d'indicateurs décisionnels, en s'appuyant sur une architecture moderne, automatisée et évolutive.

🎯 OBJECTIFS ATTEINTS

Le projet répond aux principaux besoins définis au départ :

- Centralisation des données RH et sportives.
- Nettoyage, contrôle qualité et enrichissement des données.
- Validation des distances domicile-entreprise grâce à Google Maps.
- Calcul automatique des indicateurs métier (KPI RH).
- Automatisation complète du traitement quotidien avec Kestra.
- Restitution des résultats dans un tableau de bord interactif avec Tableau Public.

🏗️ ARCHITECTURE MISE EN ŒUVRE

L'ensemble du projet repose sur une architecture Medallion organisée en trois couches :

- **Bronze** : stockage des données brutes.
- **Silver** : nettoyage, enrichissement et contrôles qualité.
- **Gold** : calcul des KPI métier destinés à la prise de décision.

Cette séparation facilite la maintenance, la réutilisation des données et l'évolution des traitements.

✅ BÉNÉFICES POUR L'ENTREPRISE

Grâce à cette solution, l'entreprise peut :

- Automatiser les traitements sans intervention manuelle.
- Suivre les indicateurs RH en temps réel.
- Calculer automatiquement les primes sportives.
- Identifier les salariés éligibles aux journées bien-être.
- Réduire les risques d'erreurs liés aux traitements manuels.
- Disposer d'une base fiable pour le pilotage des politiques RH.

🔮 PERSPECTIVES D'ÉVOLUTION

Cette architecture peut être enrichie avec de nouvelles fonctionnalités, par exemple :

- Gestion de nouveaux avantages RH.
- Prise en compte de nouveaux modes de mobilité.
- Intégration de données issues d'applications sportives connectées.
- Déploiement sur une plateforme Cloud pour améliorer la scalabilité.
- Mise en place d'analyses prédictives afin d'anticiper les comportements des salariés.